

Selecao Ativa de Restricoes em Logica Probabilistica Intervalar

Adaptacao de Valor da Informacao ao projeto Probabilidades do Solo

1. Problema de pesquisa

Uma selecao ativa orientada pela consulta identifica regras ou restricoes que reduzem o intervalo usando menos informacoes que a selecao aleatoria ou baseada apenas em suporte e confianca?

Motivacao: programas em logica probabilistica representam conhecimento sem exigir uma rede probabilistica predefinida. Essa flexibilidade cria muitas formulas e restricoes; o problema passa a ser decidir quais informacoes realmente estreitam a resposta da consulta atual.

2. Relacao com o artigo-base

Ghosh e Ramakrishnan (2019) definem Valor da Informacao para escolher observacoes que aumentam a utilidade de uma consulta em um programa logico probabilistico. O presente trabalho preserva a ideia de selecao orientada pela consulta, mas adapta informacao, utilidade e custo ao modelo com respostas intervalares.

Conceito	Artigo-base	Adaptacao intervalar
Informacao	Observavel e realizacao	Restricao Apriori candidata
Consulta	Proposicao ground q	$P(\text{label}=\text{apple} \mid \text{ph}=\text{acido}, \text{rainfall}=\text{alto})$
Incerteza	Entropia da consulta	Largura $W = U - L$
Utilidade	Menos entropia esperada	Menor intervalo da resposta
Custo	Custo do observavel	Uma unidade por restricao incluida
Politica	Maior Vol no cenario	Maior violacao de p_L ou p_U

3. Modelo matematico

Se F e a regio factivel das distribuicoes apos Charnes-Cooper, a consulta $q(z)$ possui limite inferior $L(F)$, limite superior $U(F)$ e largura $W(F)$.

$$\begin{aligned} L(F) &= \min_{(z \text{ em } F)} q(z); \quad U(F) = \max_{(z \text{ em } F)} q(z); \quad W(F) = U(F) - L(F) \\ \text{ganho}(C \mid F) &= W(F) - W(F \text{ intersecao } C) \\ \text{score}(C) &= \max(0, \max(A_C \text{ z_L}), \max(A_C \text{ z_U})); \text{ escolher } C^* = \text{argmax score}(C) \end{aligned}$$

Politica numerica obrigatoria: toda probabilidade empirica entra com seu valor completo p . As faixas sao $\max(0, p - 0,001)$ e $\min(1, p + 0,001)$, sem `round()` no modelo ou nos solvers. Casas decimais reduzidas aparecem apenas na exibicao.

4. Poda exata

Se p_L satisfaz C , ele continua factivel em $F \text{ intersecao } C$; como esse conjunto e subconjunto de F , o limite inferior permanece L . O mesmo argumento vale para p_U e o limite superior.

Logo, a factibilidade e testada por multiplicacao matriz-vetor. O HiGHS e chamado somente para o limite cujo extremo foi cortado pela nova restricao. A exatidao refere-se a poda; a escolha da maior violacao continua gulosa.

5. Experimento controlado

Consulta de referencia: $P(\text{label}=\text{apple} \mid \text{ph}=\text{acido}, \text{rainfall}=\text{alto})$. O modelo-base usa 694 registros de marginais e pares. O universo possui 2707 restricoes Apriori; o filtro de relevancia reteve 46 candidatas e o orcamento foi 25 restricoes.

Modelo	Restricoes	L	U	U - L
Base: marginais e pares	0	0.052679	0.269694	0.217015
Selecao ativa	23	0.130790	0.153846	0.023056
Suporte/confianca	23	0.088102	0.182576	0.094475
Aleatoria: media de 5	23	-	-	0.070445
Todas as relevantes	46	0.130790	0.153846	0.023056
Modelo completo atual	2707	0.130790	0.153846	0.023056

6. Resultado

A selecao ativa reduziu a largura em 0.193959, ou 89.38%. Com apenas 23 restricoes, recuperou 100.00% da reducao observada no modelo completo atual. Sob o mesmo orcamento, o baseline de suporte/confianca terminou com largura 0.094475, e a media aleatoria terminou com 0.070445.

7. Avaliacao em dez consultas

Para evitar concluir a partir de um unico caso, o experimento repete o protocolo em dez culturas sob as mesmas condicoes $\text{ph}=\text{acido}$ e $\text{rainfall}=\text{alto}$, incluindo tres consultas sem ocorrencia conjunta na amostra. O efeito nao e universal por consulta; os resultados agregados sustentam a vantagem media da selecao ativa.

Indicador em multiplas consultas	Resultado
Consultas avaliadas	10
Largura media do modelo-base	0.067066
Largura media da selecao ativa	0.015597
Reducao relativa media	36.45%
Largura media por suporte/confianca	0.043087
Largura media aleatoria	0.026353
Vitorias sobre suporte/confianca	4 de 10
Vitorias sobre a media aleatoria	4 de 10
Taxa media de poda exata	66.13%
Taxa media total de chamadas evitadas	97.23%

8. Custo computacional

Indicador	Valor
Candidatas Apriori disponiveis	2707
Candidatas relevantes avaliadas	46
Verificacoes algebricas dos extremos	1656
Reotimizacoes seletivas executadas	35
Podas exatas por factibilidade	1200
Taxa de poda exata	72.46%
Chamadas candidatas evitadas no total	1621
Taxa total de chamadas evitadas	97.89%
Subconjuntos da busca exaustiva	8233430727600
Tempo total	9.264 s

A busca nao enumera subconjuntos. Em cada passo, examina as restricoes restantes com operacoes algebricas e resolve no maximo dois PLs, um por extremo violado. Os baselines sao calculados apenas para avaliacao experimental.

9. Rastro auditavel da selecao

A tabela mostra a ordem gulosa, quais extremos foram violados e a largura apos cada inclusao. Reducao nula em um passo pode ocorrer quando existe outra solucao otima no mesmo extremo; restricoes sucessivas podem eliminar essa face otima.

Passo	ID	Restricao escolhida	Viola p_L	Viola p_U	PLs	U - L
1	R3367	P(ph=acido, rainfall=alto, temperature=baixo)	sim	sim	2	0.217015
2	R2704	P(label=apple, ph=acido, rainfall=medio)	sim	sim	2	0.043242
3	R3366	P(ph=acido, rainfall=alto, temperature=alto)	sim	sim	2	0.043242
4	R1939	P(N=medio, ph=acido, rainfall=alto)	sim	sim	2	0.043242
5	R2351	P(P=medio, ph=acido, rainfall=alto)	sim	sim	2	0.043242
6	R1837	P(N=medio, label=apple, ph=acido)	nao	sim	1	0.043242
7	R2203	P(P=baixo, ph=acido, rainfall=alto)	nao	sim	1	0.043242
8	R1838	P(N=medio, label=apple, rainfall=alto)	nao	sim	1	0.043242
9	R2717	label=apple, rainfall=alto -> temperature=baixo	sim	sim	2	0.043242
10	R1503	P(N=alto, ph=acido, rainfall=alto)	sim	sim	2	0.043242
11	R2554	P(humidity=baixo, ph=acido, rainfall=alto)	sim	sim	2	0.043242
12	R2706	label=apple, ph=acido -> temperature=baixo	sim	sim	2	0.043242
13	R1329	P(K=medio, ph=acido, rainfall=alto)	sim	nao	1	0.043242
14	R2710	P(label=apple, ph=neutro, rainfall=alto)	sim	nao	1	0.043242
15	R2703	P(label=apple, ph=acido, rainfall=alto)	sim	sim	2	0.023056
16	R2667	P(humidity=medio, ph=acido, rainfall=alto)	nao	sim	1	0.023056
17	R3368	P(ph=acido, rainfall=alto, temperature=medio)	sim	nao	1	0.023056
18	R3250	label=pigeonpeas, ph=acido -> rainfall=alto	sim	sim	2	0.023056
19	R2079	P(P=alto, ph=acido, rainfall=alto)	nao	sim	1	0.023056
20	R0878	P(K=alto, ph=acido, rainfall=alto)	sim	nao	1	0.023056
21	R1716	P(N=baixo, ph=acido, rainfall=alto)	sim	nao	1	0.023056
22	R1138	P(K=baixo, ph=acido, rainfall=alto)	sim	nao	1	0.023056
23	R1624	P(N=baixo, label=apple, ph=acido)	sim	sim	2	0.023056

10. Validade e limites

A poda de cada extremo e exata. A escolha gulosa pela maior violacao e uma heuristica e nao garante o subconjunto globalmente otimo. O filtro de relevancia tambem reduz o universo de busca. Os intervalos e regras foram obtidos in-sample na mesma base agricola. A evidencia apoia esta demonstracao controlada, nao uma afirmacao geral sobre desempenho agronomico ou sobre todos os programas logico-probabilisticos.

11. Conclusao

Na consulta de referencia e na media do conjunto avaliado, a selecao orientada pelos extremos produziu intervalo menor que os baselines sob o mesmo orcamento, embora nao tenha vencido em todas as consultas. A poda reduziu substancialmente as chamadas ao solver. A contribuicao e uma adaptacao aplicada; Valor da Informacao e programacao linear probabilistica nao sao apresentados como tecnicas novas.

Referencia. Ghosh, S.; Ramakrishnan, C. R. Value of Information in Probabilistic Logic Programs. EPTCS 306, p. 71-84, 2019. DOI: 10.4204/EPTCS.306.14. arXiv:1909.08234.