

Selecao Ativa de Restricoes em Logica Probabilistica Intervalar

Adaptacao de Valor da Informacao ao projeto Probabilidades do Solo

1. Problema de pesquisa

Uma selecao ativa orientada pela consulta identifica regras ou restricoes que reduzem o intervalo usando menos informacoes que a selecao aleatoria ou baseada apenas em suporte e confianca?

Motivacao: programas em logica probabilistica representam conhecimento sem exigir uma rede probabilistica predefinida. Essa flexibilidade cria muitas formulas e restricoes; o problema passa a ser decidir quais informacoes realmente estreitam a resposta da consulta atual.

2. Relacao com o artigo-base

Ghosh e Ramakrishnan (2019) definem Valor da Informacao para escolher observacoes que aumentam a utilidade de uma consulta em um programa logico probabilistico. O presente trabalho preserva a ideia de selecao orientada pela consulta, mas adapta informacao, utilidade e custo ao modelo com respostas intervalares.

Conceito	Artigo-base	Adaptacao intervalar
Informacao	Observavel e realizacao	Restricao Apriori candidata
Consulta	Proposicao ground q	$P(\text{label}=\text{rice} \mid \text{ph}=\text{acido}, \text{rainfall}=\text{alto})$
Incerteza	Entropia da consulta	Largura $W = U - L$
Utilidade	Menos entropia esperada	Menor intervalo da resposta
Custo	Custo do observavel	Uma unidade por restricao incluida
Politica	Maior Vol no cenario	Maior violacao de p_L ou p_U

3. Modelo matematico

Se F e a regio factivel das distribuicoes apos Charnes-Cooper, a consulta $q(z)$ possui limite inferior $L(F)$, limite superior $U(F)$ e largura $W(F)$.

$$\begin{aligned} L(F) &= \min_{(z \text{ em } F)} q(z); \quad U(F) = \max_{(z \text{ em } F)} q(z); \quad W(F) = U(F) - L(F) \\ \text{ganho}(C \mid F) &= W(F) - W(F \text{ intersecao } C) \\ \text{score}(C) &= \max(0, \max(A_C \text{ z_L}), \max(A_C \text{ z_U})); \text{ escolher } C^* = \text{argmax score}(C) \end{aligned}$$

4. Poda exata

Se p_L satisfaz C , ele continua factivel em $F \text{ intersecao } C$; como esse conjunto e subconjunto de F , o limite inferior permanece L . O mesmo argumento vale para p_U e o limite superior.

Logo, a factibilidade e testada por multiplicacao matriz-vetor. O HiGHS e chamado somente para o limite cujo extremo foi cortado pela nova restricao. A exatidao refere-se a poda; a escolha da maior violacao continua gulosa.

5. Experimento controlado

Consulta de referencia: $P(\text{label}=\text{rice} \mid \text{ph}=\text{acido}, \text{rainfall}=\text{alto})$. O modelo-base usa 694 registros de marginais e pares. O universo possui 2707 restricoes Apriori; o filtro de relevancia reteve 52 candidatas e o orcamento foi 25 restricoes.

Modelo	Restricoes	L	U	U - L
Base: marginais e pares	0	0.140000	0.163265	0.023265
Selecao ativa	25	0.144181	0.163265	0.019084
Suporte/confianca	25	0.140000	0.163265	0.023265
Aleatoria: media de 5	25	-	-	0.022122
Todas as relevantes	52	0.144181	0.163265	0.019084
Modelo completo atual	2707	0.144285	0.162899	0.018614

6. Resultado

A selecao ativa reduziu a largura em 0.004181, ou 17.97%. Com apenas 25 restricoes, recuperou 89.90% da reducao observada no modelo completo atual. Sob o mesmo orcamento, o baseline de suporte/confianca terminou com largura 0.023265, e a media aleatoria terminou com 0.022122.

7. Avaliacao em dez consultas

Para evitar concluir a partir de um unico caso, o experimento repete o protocolo em dez culturas sob as mesmas condicoes $\text{ph}=\text{acido}$ e $\text{rainfall}=\text{alto}$, incluindo tres consultas sem ocorrencia conjunta na amostra. O efeito nao e universal por consulta; os resultados agregados sustentam a vantagem media da selecao ativa.

Indicador em multiplas consultas	Resultado
Consultas avaliadas	10
Largura media do modelo-base	0.066857
Largura media da selecao ativa	0.014312
Reducao relativa media	41.31%
Largura media por suporte/confianca	0.040575
Largura media aleatoria	0.022285
Vitorias sobre suporte/confianca	6 de 10
Vitorias sobre a media aleatoria	5 de 10
Taxa media de poda exata	66.29%
Taxa media total de chamadas evitadas	97.28%

8. Custo computacional

Indicador	Valor
Candidatas Apriori disponiveis	2707
Candidatas relevantes avaliadas	52
Verificacoes algebricas dos extremos	2000
Reotimizacoes seletivas executadas	43
Podas exatas por factibilidade	1446
Taxa de poda exata	72.30%
Chamadas candidatas evitadas no total	1957
Taxa total de chamadas evitadas	97.85%
Subconjuntos da busca exaustiva	477551179875952
Tempo total	10.201 s

A busca nao enumera subconjuntos. Em cada passo, examina as restricoes restantes com operacoes algebricas e resolve no maximo dois PLs, um por extremo violado. Os baselines sao calculados apenas para avaliacao experimental.

9. Rastro auditavel da selecao

A tabela mostra a ordem gulosa, quais extremos foram violados e a largura apos cada inclusao. Reducao nula em um passo pode ocorrer quando existe outra solucao otima no mesmo extremo; restricoes sucessivas podem eliminar essa face otima.

Passo	ID	Restricao escolhida	Viola p_L	Viola p_U	PLs	U - L
1	R1939	P(N=medio, ph=acido, rainfall=alto)	sim	sim	2	0.023265
2	R3368	P(ph=acido, rainfall=alto, temperature=medio)	sim	sim	2	0.023265
3	R2079	P(P=alto, ph=acido, rainfall=alto)	sim	sim	2	0.023265
4	R2453	P(humidity=alto, ph=acido, rainfall=alto)	sim	sim	2	0.023265
5	R1138	P(K=baixo, ph=acido, rainfall=alto)	sim	sim	2	0.023265
6	R1503	P(N=alto, ph=acido, rainfall=alto)	sim	sim	2	0.023265
7	R3367	P(ph=acido, rainfall=alto, temperature=baixo)	sim	sim	2	0.023265
8	R3250	label=pigeonpeas, ph=acido -> rainfall=alto	sim	sim	2	0.023265
9	R0878	P(K=alto, ph=acido, rainfall=alto)	sim	sim	2	0.023265
10	R2351	P(P=medio, ph=acido, rainfall=alto)	sim	sim	2	0.023265
11	R2667	P(humidity=medio, ph=acido, rainfall=alto)	sim	sim	2	0.023265
12	R3366	P(ph=acido, rainfall=alto, temperature=alto)	nao	sim	1	0.023265
13	R3314	label=rice, ph=acido -> K=medio	sim	sim	2	0.023265
14	R3315	label=rice, ph=acido -> P=medio	sim	sim	2	0.023265
15	R1329	P(K=medio, ph=acido, rainfall=alto)	sim	sim	2	0.023265
16	R3329	label=rice, rainfall=alto -> P=medio	sim	sim	2	0.023265
17	R2703	P(label=apple, ph=acido, rainfall=alto)	nao	sim	1	0.023265
18	R2652	P(humidity=medio, label=rice, ph=acido)	sim	nao	1	0.023265
19	R1716	P(N=baixo, ph=acido, rainfall=alto)	sim	nao	1	0.023265
20	R3327	label=rice, rainfall=alto -> K=medio	sim	sim	2	0.023265
21	R1488	P(N=alto, label=rice, ph=acido)	sim	nao	1	0.023265
22	R3328	label=rice, rainfall=alto -> N=alto	sim	sim	2	0.023265
23	R2203	P(P=baixo, ph=acido, rainfall=alto)	nao	sim	1	0.023265
24	R3316	label=rice, ph=acido -> humidity=medio	sim	sim	2	0.019084
25	R2554	P(humidity=baixo, ph=acido, rainfall=alto)	nao	sim	1	0.019084

10. Validade e limites

A poda de cada extremo e exata. A escolha gulosa pela maior violacao e uma heuristica e nao garante o subconjunto globalmente otimo. O filtro de relevancia tambem reduz o universo de busca. Os intervalos e regras foram obtidos in-sample na mesma base agricola. A evidencia apoia esta demonstracao controlada, nao uma afirmacao geral sobre desempenho agronomico ou sobre todos os programas logico-probabilisticos.

11. Conclusao

Na consulta de referencia e na media do conjunto avaliado, a selecao orientada pelos extremos produziu intervalo menor que os baselines sob o mesmo orcamento, embora nao tenha vencido em todas as consultas. A poda reduziu substancialmente as chamadas ao solver. A contribuicao e uma adaptacao aplicada; Valor da Informacao e programacao linear probabilistica nao sao apresentados como tecnicas novas.

Referencia. Ghosh, S.; Ramakrishnan, C. R. Value of Information in Probabilistic Logic Programs. EPTCS 306, p. 71-84, 2019. DOI: 10.4204/EPTCS.306.14. arXiv:1909.08234.