

Relatorio da Saida do Sistema

Consulta probabilistica com dataset categorico, regras de associacao e resolucao por programacao linear.

1. Objetivo

O sistema permite que o usuario escolha afirmacoes na interface e formule uma pergunta condicional. A aplicacao Python le o dataset, extrai probabilidades, monta restricoes lineares e usa um solver para obter um intervalo de resposta para $P(A | B)$.

2. Dataset e dinamica da interface

O dataset carregado possui 2200 registros. O sistema detecta automaticamente as colunas do CSV, identifica atributos numericos, converte esses atributos em categorias e envia os dominios para o frontend. Assim, os campos da interface sao montados dinamicamente a partir da propria base.

Item	Valor
Atributos	N, P, K, temperature, humidity, ph, rainfall, label
Numericos categorizados	N, P, K, temperature, humidity, ph, rainfall
Categoricos originais	label
Mundos observados	466

3. Tempo de processamento

Campo	Valor
Inicio	2026-07-29T02:03:48.055369+00:00
Fim	2026-07-29T02:03:53.904420+00:00
Duracao	5.849 segundos
Etapas medidas	Carga/preparacao dos dados, probabilidades, restricoes e solver linear.

4. Algoritmos matematicos usados

Abaixo estao os principais algoritmos matematicos implementados no backend Python. Eles explicam como o dataset vira probabilidades, restricoes e uma consulta resolvida por programacao linear.

Etapas	Formula/algoritmo	Finalidade
Discretizacao	atributo numerico $\leq Q1 \rightarrow$ baixo; $\leq Q2 \rightarrow$ medio; $Q2 < \text{atributo} \leq Q3 \rightarrow$ alto	Transformar variaveis numericas em categorias para montar regras
Probabilidade marginal	$P(E) = \text{contagem}(E) / N$	Medir a frequencia de um evento simples, como $P(\text{label}=\text{rico})$
Probabilidade conjunta	$P(A \text{ e } B) = \text{contagem}(A \text{ e } B) / N$	Medir a frequencia de eventos que acontecem ao mesmo tempo
Probabilidade condicional	$P(A B) = P(A \text{ e } B) / P(B)$	Responder a pergunta feita pelo usuario na interface.
Suporte	$\text{suporte}(B \rightarrow A) = P(A \text{ e } B)$	Indicar quanto a regra completa aparece na base.
Confianca/precisao	$\text{confianca}(B \rightarrow A) = P(A B)$	Indicar a chance de A acontecer quando B acontece.
Lift	$\text{lift}(B \rightarrow A) = P(A B) / P(A)$	Comparar a regra com a probabilidade marginal de A.

Etapa	Formula/algorithmo	Finalidade
Intervalo	$\text{round}(p, 3) - 0,001 \leq P(E) \leq \text{round}(p, 3) + 0,001$	Evitar rigidez numerica e representar probabilidade intervalar
Variavel linear	$x_w \geq 0$ para cada mundo possivel w ; $\text{soma}(x_w) = 1$	Representar uma distribuicao de probabilidade valida.
Restricao linear	$L \leq \text{soma}(x_w \text{ onde } E \text{ ocorre}) \leq U$	Converter probabilidades extraidas da base em restricoes
Charnes-Cooper	$P(A \text{ e } B)/P(B) \rightarrow x_w = y_w/t$, com $P(B)$ em $y = 1$	Transformar a consulta condicional fracionaria em problema

Pseudocodigo resumido:

1. Ler CSV e detectar colunas.
2. Converter atributos numericos para categorias.
3. Agrupar linhas em mundos possiveis w .
4. Calcular $P(A)$, $P(B)$, $P(A \text{ e } B)$, suporte, confianca e lift.
5. Criar restricoes intervalares para as probabilidades observadas.
6. Resolver minimo e maximo da consulta condicional com `scipy.optimize.linprog`.

5. Exemplo de pergunta do usuario

Na interface, o usuario pode escolher uma pergunta A e uma ou mais condicoes B. No exemplo abaixo:


```
A = label=rice
B = ph=acido, rainfall=alto
```

Consulta: $P(\text{label}=\text{rice} \mid \text{ph}=\text{acido}, \text{rainfall}=\text{alto})$

6. Saida probabilistica

Metrica	Valor	Interpretacao
$P(A)$	0,045	Probabilidade marginal da cultura rice.
$P(B)$	0,099	Probabilidade das condicoes escolhidas.
Suporte $P(A \text{ e } B)$	0,015	Frequencia da regra completa na base.
Confianca $P(A \mid B)$	0,151	Probabilidade de A quando B ocorre.
Lift	3,330	Forca da regra comparada com $P(A)$.
Instancias	33 / 218	Casos que satisfazem A e B sobre casos que satisfazem B.


Grafico das probabilidades calculadas



7. Grafico do intervalo linear

O grafico abaixo compara o valor empirico da confianca com o intervalo calculado pelo solver. O intervalo aparece porque as probabilidades do dataset sao usadas como restricoes aproximadas, com

arredondamento em tres casas decimais.



8. Probabilidades lineares consideradas

No modelo atual entram automaticamente as probabilidades lineares mais importantes para responder a consulta escolhida. Elas são somas de variáveis x_w , portanto podem ser escritas diretamente como restrições lineares.

Tipo	Forma	Status no sistema
Marginal	$P(\text{valor de atributo})$	Incluída para todos os valores de todos os atributos.
Evento A	$P(A)$	Incluída conforme a pergunta do usuário.
Condições B	$P(B)$	Incluída conforme as afirmações do usuário.
Conjunta da regra	$P(A \text{ e } B)$	Incluída para calcular suporte e condicional.
Suporte	$P(A \text{ e } B)$	Linear direto.
Condicional	$P(A B)$	Resolvida por transformação linear-fracionária.
Conjuntas de pares	$P(X=x, Y=y)$	Possível extensão; não entra por padrão para evitar explosão combinatorial.
Conjuntas de trios ou mais	$P(X=x, Y=y, Z=z)$	Possível extensão; aumenta muito variáveis/restrições.

9. Programação linear

Cada mundo possível w recebe uma variável x_w , que representa a probabilidade daquela combinação categorizada. As probabilidades extraídas do dataset são convertidas em restrições intervalares com três casas decimais. A consulta condicional é resolvida como um problema linear-fracionário transformado em programação linear.

```
Variáveis:
 $x_w \geq 0$  para cada mundo possível  $w$  da base categorizada

Restrição de normalização:
 $\text{soma}(x_w) = 1$ 

Restrições extraídas da base:
 $0.044 \leq P(A) = \text{soma}(x_w \text{ onde label=rice}) \leq 0.046$ 
 $0.098 \leq P(B) = \text{soma}(x_w \text{ onde ph=acido, rainfall=alto}) \leq 0.100$ 
 $0.014 \leq P(A \text{ e } B) = \text{soma}(x_w \text{ onde ph=acido, rainfall=alto, label=rice}) \leq 0.016$ 

Consulta:
 $P(A | B) = P(A \text{ e } B) / P(B)$ 

Resolução linear:
A razão  $P(A \text{ e } B) / P(B)$  é convertida por Charnes-Cooper:
 $x_w = y_w / t$ 
 $P(B)$  em  $y$  é fixado como 1
minimizar  $\text{soma}(y_w \text{ onde } A \text{ e } B)$  para o limite inferior
maximizar  $\text{soma}(y_w \text{ onde } A \text{ e } B)$  para o limite superior
```

```
Solver: scipy.optimize.linprog highs  
Variaveis: 466  
Restricoes: 94  
Intervalo retornado: 0.140 <= P(A | B) <= 0.163
```

10. Saida final apresentada ao usuario

A interface apresenta o valor empirico da confianca, as metricas de regra de associacao e o intervalo obtido pelo solver. Para o exemplo:

```
P(label=rice | ph=acido, rainfall=alto) = 0,151  
Intervalo linear: 0,140 <= P(A | B) <= 0,163  
Solver: scipy.optimize.linprog highs
```

11. Arquivo de saida calculada

Alem do PDF, o gerador salva um JSON com a consulta, probabilidades, contagens e resultado do solver. Esse arquivo pode ser usado como evidencia objetiva da execucao do sistema.

```
reports/saida_calculada_programacao_linear.json
```

12. Relacao com o enunciado

A saida comprova que o sistema extrai conhecimento probabilistico da base, expressa suporte e confianca como probabilidades, transforma as probabilidades em restricoes lineares, permite perguntas condicionais pela interface e resolve a consulta com solver de programacao linear.